

Predição da Ocorrência de Diabetes em Pacientes

Marcos dos Santos Silva¹, Victor Luis Lima Souza^{1,2}

¹Faculdade de Computação e Informática (FCI)
Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

{10410484, 10310277}@mackenzie.br

Resumo. O objetivo do projeto é criar um modelo, empregando técnicas de Machine Learning, para prever a incidência de diabetes em pacientes com base no conjunto de dados Pima Indians Diabetes disponível na plataforma Kaggle. A pesquisa será realizada por meio da utilização de algoritmos de classificação supervisionada. Uma análise exploratória dos dados será conduzida, além do pré-processamento, com o objetivo de criar um modelo preditivo que ajude na tomada de decisões na área da saúde, auxiliando profissionais a identificar pacientes com maior probabilidade de desenvolver diabetes.

Palavras-chave: Inteligência Artificial; Machine Learning; Classificação; Previsão de Diabetes; Saúde.

Abstract. The goal of this project is to create a model using Machine Learning techniques to predict the incidence of diabetes in patients based on the Pima Indians Diabetes dataset available on the Kaggle platform. The research will be conducted through the use of supervised classification algorithms. An exploratory data analysis will be performed, along with preprocessing, with the aim of creating a predictive model that supports decision-making in the healthcare field, helping professionals identify patients with a higher probability of developing diabetes.

Keywords: Artificial Intelligence; Machine Learning; Classification; Diabetes Prediction; Healthcare.

1. Introdução

1.1. Contextualização

A diabetes é uma das doenças crônicas mais comuns no mundo e vem apresentando um crescimento significativo nos últimos anos. Essa condição pode trazer diversas complicações para a saúde, especialmente quando não é diagnosticada ou tratada corretamente. Por isso, a detecção precoce se torna essencial, pois permite que médicos e pacientes tomem decisões de forma mais ágil e eficaz.

Segundo a Organização Mundial da Saúde (OMS), a prevalência global de diabetes em adultos passou de 7% em 1990 para 14% em 2022. Atualmente, estima-se que cerca de 589 milhões de adultos entre 20 e 79 anos vivam com diabetes, número que pode chegar a aproximadamente 853 milhões até 2050. (INTERNATIONAL DIABETES FEDERATION, 2023)

Além disso, os impactos da doença vão além da saúde individual, envolvendo também custos econômicos relevantes para sistemas de saúde e para a sociedade. Nos Estados Unidos, por exemplo, pessoas diagnosticadas com diabetes possuem gastos médicos, em média, 2,6 vezes maiores do que aquelas sem a doença (ZHU et al., 2023).

1.2. Justificativa

O aumento expressivo dos casos de diabetes no mundo reforça a necessidade de desenvolver ferramentas que auxiliem na sua detecção precoce. Quanto mais cedo um paciente é identificado com risco de desenvolver a doença, maiores são as chances de receber o acompanhamento adequado e evitar complicações futuras. Nesse contexto, métodos computacionais baseados em dados podem apoiar profissionais de saúde na tomada de decisão.

A Inteligência Artificial tem se destacado na área da saúde justamente por permitir a análise de grandes volumes de dados e a identificação de padrões que, muitas vezes, não são facilmente percebidos por humanos. Assim, torna-se possível criar modelos capazes de prever doenças, como a diabetes, a partir de informações dos pacientes.

Dessa forma, o uso de Machine Learning para a previsão de diabetes não representa apenas uma aplicação prática dos conceitos estudados na disciplina, mas também uma contribuição relevante para a área da saúde, ao oferecer suporte adicional a médicos e instituições no processo de diagnóstico e prevenção.

1.3. Objetivo

O objetivo deste projeto é desenvolver um modelo de Machine Learning capaz de prever a ocorrência de diabetes em pacientes, utilizando a base de dados Pima Indians Diabetes, disponível no Kaggle. Para isso, serão aplicados algoritmos de classificação supervisionada.

1.4. Opção do Projeto

A opção escolhida para o desenvolvimento do projeto foi a Opção Framework, que consiste em empregar bibliotecas e ferramentas de Machine Learning em Python para a resolução de um problema de classificação. Para isso, será utilizado o framework scikitlearn e pandas, aplicando diferentes algoritmos supervisionados sobre o conjunto de dados selecionado.

2. Descrição do Problema

A diabetes é uma doença que, quando não diagnosticada a tempo, pode causar diversas complicações à saúde. Além disso, seus sintomas nem sempre se manifestam de forma clara, o que dificulta sua identificação. Isso evidencia a necessidade de métodos capazes de analisar variáveis clínicas e indicar a probabilidade de um paciente desenvolver a doença.

O problema a ser resolvido consiste justamente na previsão da diabetes em pacientes, a partir de informações clínicas básicas, como níveis de glicose, índice de massa corporal, pressão arterial e idade. A proposta é utilizar algoritmos de classificação supervisionada para construir um modelo que auxilie no diagnóstico, apoiando os profissionais de saúde.

3. Aspectos Éticos do uso da IA

As decisões baseadas em modelos preditivos podem impactar diretamente a vida das pessoas, por isso é fundamental que a Inteligência Artificial seja utilizada como ferramenta de apoio, e não como substituta da avaliação médica. Isso porque erros de classificação podem levar a diagnósticos incorretos. Outro ponto importante envolve a privacidade e a proteção dos dados dos pacientes, já que essas informações são sensíveis e devem ser tratadas com segurança, garantindo anonimização quando necessário e evitando qualquer uso indevido.

Além disso, caso o conjunto de dados não represente adequadamente diferentes perfis de pacientes, o modelo pode gerar resultados que não sejam generalizáveis. Por isso, cabe ao desenvolvedor avaliar a qualidade dos dados e buscar minimizar esses problemas, tornando a solução mais confiável.

4. Descrição detalhada do Dataset

O dataset utilizado neste projeto é o Pima Indians Diabetes Database, disponível na plataforma Kaggle. Ele foi coletado pelo National Institute of Diabetes and Digestive and Kidney Diseases e contém informações clínicas de mulheres com pelo menos 21 anos, pertencentes ao grupo indígena Pima, na região do Arizona, nos Estados Unidos.

A base possui 768 registros, cada um representando um paciente, e conta com 8 variáveis independentes: número de gestações, nível de glicose, pressão arterial, espessura da pele, nível de insulina, índice de massa corporal (IMC), histórico familiar de diabetes (Diabetes Pedigree Function) e idade. A variável dependente é binária, indicando se o paciente possui (1) ou não possui (0) diabetes.

Como os dados disponibilizados já são anônimos, não foi necessária nenhuma etapa adicional de anonimização.

A primeira etapa do trabalho consistiu no carregamento do dataset utilizando a biblioteca Pandas. Em seguida, foi realizada uma análise exploratória inicial para melhor compreensão da base. Foram avaliadas informações gerais, como quantidade de linhas, colunas e tipos de dados, além do cálculo de estatísticas descritivas, como média, mediana, valores mínimos e máximos.

Outro ponto analisado foram os valores ausentes e inválidos. Algumas variáveis, como glicose, pressão arterial, espessura da pele, insulina e IMC, apresentavam valores iguais a zero, o que não é plausível. Esses valores foram tratados substituindo-os por NaN (valores nulos) e, posteriormente, preenchendo-os com a mediana de cada coluna. Essa abordagem foi escolhida por ser menos sensível a valores extremos, tornando o dataset mais consistente.

5. Metodologia

Inicialmente, foi aplicada a análise exploratória do dataset, com o objetivo de compreender melhor as variáveis disponíveis e identificar possíveis inconsistências. Em seguida, foi feito o pré-processamento dos dados, incluindo normalização e divisão em conjuntos de treino e teste.

Na etapa seguinte, serão aplicados algoritmos de classificação supervisionada utilizando a biblioteca scikit-learn. O desempenho dos modelos foi avaliado por meio de métricas como acurácia e precisão, permitindo a comparação entre os resultados obtidos.

Como resultados esperados, busca-se desenvolver um modelo preditivo confiável, capaz de identificar pacientes com maior risco de diabetes a partir dos dados analisados. Além disso, espera-se demonstrar que o uso de Machine Learning pode contribuir para a área da saúde, oferecendo uma ferramenta adicional para a detecção da doença e auxiliando na tomada de decisão dos profissionais.

6. Resultados obtidos

Os dois modelos apresentaram resultados dentro do esperado. A Regressão Logística teve acurácia de 70%, com bom equilíbrio entre as classes. O KNN também teve desempenho próximo, mas foi um pouco mais sensível ao valor de k e à normalização, apresentando acurácia de 0.7532 e precisão de 0.6600, sendo o modelo com melhor desempenho geral. Já a Regressão Logística apresentou acurácia de 0.7013 e precisão de 0.5870.

Em ambos os modelos, a classe negativa (sem diabetes) teve mais acertos, o que é comum no dataset por ele ser desbalanceado. Mesmo assim, os modelos conseguiram identificar uma quantidade relevante de casos positivos, mostrando utilidade prática para triagem de pacientes.

7. Conclusão

O projeto teve como objetivo desenvolver um modelo capaz de prever a ocorrência de diabetes utilizando dados clínicos básicos. Com as etapas realizadas e os testes aplicados, foi possível alcançar resultados satisfatórios. O modelo KNN obteve o melhor desempenho, enquanto a Regressão Logística também apresentou resultados consistentes, embora um pouco inferiores.

Com isso, é possível concluir que os resultados esperados foram alcançados. Os modelos construídos demonstraram capacidade de auxiliar na identificação de pacientes com risco de desenvolver diabetes, contribuindo como uma ferramenta de apoio na área da saúde.

Vale destacar, no entanto, que o dataset utilizado é restrito a mulheres do grupo indígena Pima, o que pode limitar a generalização dos resultados para outros perfis de pacientes. Como trabalhos futuros, sugere-se a aplicação de algoritmos adicionais, como Random Forest, e o uso de técnicas de validação cruzada para uma avaliação mais robusta dos modelos.

8. Endereço GitHub e Youtube

<https://github.com/Marcos11Silva07/Projeto-IA-07J/tree/main>

<https://youtu.be/oFGyc7-oepE>

9. Referências bibliográficas

- INTERNATIONAL DIABETES FEDERATION (IDF). **IDF Diabetes Atlas**. 10. ed. Bruxelas: IDF, 2023. Disponível em: <https://diabetesatlas.org>. Acesso em: 20 set. 2025.
- KAGGLE. **Pima Indians Diabetes Database**. [S.l.]: Kaggle, [2025]. Disponível em: <https://www.kaggle.com/datasets/uciml/pima-indians-diabetes-database>. Acesso em: 20 set. 2025.
- ORGANIZAÇÃO MUNDIAL DA SAÚDE (OMS). **Urgent action needed as global diabetes cases increase four-fold over past decades**. Genebra: OMS, 2024. Disponível em: <https://www.who.int/news/item/13-11-2024-urgent-action-needed-as-global-diabetes-cases-increase-four-fold-over-past-decades>. Acesso em: 20 set. 2025.
- ZHU, Y. et al. Economic costs of diabetes in the U.S. in 2022. **Diabetes Care**, [S.l.], v. 46, n. 1, p. 50-60, 2023. Disponível em: <https://pubmed.ncbi.nlm.nih.gov/37909353/>. Acesso em: 20 set. 2025.